Санкт-Петербургский государственный университет

Кафедра системного программирования

Разработка голосового помощника врача, интегрированного с медицинской информационной системой "СТОММИС", с использованием больших языковых моделей

Альшаеб Басель, группа 24.М71-мм

Санкт-Петербургский государственный университет
Кафедра системного программирования

Научный руководитель: ст. преподаватель каф. системного программирования, к.ф.-м.н. С. С. Сысоев.
Площадка апробации: СПб ГБУЗ «СП № 8»

Проблема и мотивация

- В стоматологии значимая часть данных должна быть занесена в электронную карту: жалобы, диагнозы, процедуры, материалы, рекомендации.
- В МИС «СТОММИС» исходный прототип голосового режима активировался **кнопкой** и записывал короткий фрагмент речи.
- Во время лечения врачу **неудобно взаимодействовать с компьютером**: заняты руки, перчатки, внимание на пациенте.
- Цель проекта: обеспечить **управление картой голосом прямо в процессе лечения** без ручного запуска записи.

Постановка задачи

Цель: разработать ресурсоэффективный инструмент для анализа аудиопотока из браузера и выделения команд для МИС «СТОММИС».

Задачи:

1. Детекция участков с речью и «тишиной» в аудиопотоке (VAD) в браузере.
2. Определение начала/конца командного сегмента (окончание команды — пауза ≈ 2 с).
3. Экспериментировать с активацией голосового режима:
   - KWS/wake word на клиенте;
   - активация на сервере после ASR (ограниченный список команд и/или LLM-проверка).
4. Интеграция с серверной обработкой: транскодирование аудио, ASR, интерпретация команд, формирование действий для МИС.
5. Первичная апробация и сравнение с базовым режимом (непрерывная обработка потока).

Ключевое противоречие

- Для надежного распознавания команд хочется анализировать весь аудиопоток.
- Но непрерывная отправка/распознавание аудио:
  - увеличивает нагрузку на сеть и сервер;
  - увеличивает стоимость использования облачного ASR;
  - повышает риск обработки нерелевантной речи (комментарии, шум).
- Нужен механизм, который **минимизирует ресурсы**, но **не пропускает команды**.

Обзор существующих решений

- Диктовка в медицинских системах: полный протокол приёма переводится в текст и сохраняется.
- Голосовые ассистенты общего назначения: хорошо понимают речь, но не привязаны к структуре медкарты и справочникам.
- KWS (wake word) в клиенте: локальная активация, но чувствительна к микрофону/шуму и часто требует обучения под пользователя.

Недостатки в нашем контексте: нет гарантии *структурированного* заполнения карты и сложно обеспечить устойчивую активацию при низком потреблении ресурсов.

Отличие от типовых решений

- Мы не просто сохраняем речь: результатом являются **структурированные действия** в МИС.
- Команды интерпретируются и сопоставляются с **деревом сущностей** (диагнозы, процедуры, материалы) и полями карточки пациента.
- Предусмотрена фильтрация:
  - **вход**: VAD + активация, чтобы отсекать «тишину» и нерелевантный поток;
  - **выход**: ограничение допустимых команд и параметров (контроль формата ответа).

Архитектура решения

- **Клиент (браузер):**
  - захват микрофона (WebAudio);
  - VAD (`@ricky0123/vad-web`) выделяет сегменты речи;
  - Сегмент речи отправляется на сервер, где проверяется слово активации; при успехе запускается захват и обработка команды.
- **Сервер (поликлиника):**
  - приём аудио (`multipart/form-data`, поле `file`);
  - транскодирование в Ogg/Opus (FFmpeg);
  - ASR (Yandex Speech) $\rightarrow$ текст;
  - Проверка слова активации;
  - интерпретация (LLM) $\rightarrow$ структурированная команда $\rightarrow$ действие в МИС.

Активация голосового режима: что пробовали

- **Вариант 1 (браузер, KWS):** локальное распознавание «start»/«старт».
  - Плюс: не отправляет аудио на сервер до активации.
  - Минусы: много **FN** (пропусков) в шумной среде, зависит от микрофона, требует **обучения/калибровки на каждом враче**.
- **Вариант 2 (сервер, после ASR):** активация по распознанному тексту + ограниченный список команд / LLM-проверка.
  - Устойчивее, не требует обучения, но зависит от качества ASR.

В итоговой схеме основной режим — *серверная* проверка активации; клиентская KWS оставлена как опциональная.

Технические детали: сервер пайплайн

- **Вход:** аудиофайл сегмента команды из браузера (`multipart/form-data`, поле `file`).
- Приём аудио в Flask:

```
if "file" not in request.files: ...
raw = request.files["file"].read()
```

- **Нормализация формата:** транскодирование в Ogg/Opus (FFmpeg) для стабильного ASR.

```
ffmpeg -i pipe:0 -c:a libopus -b:a 48k
```

- **Распознавание речи (ASR):** Yandex Speech → транскрипция команды.
- **Интерпретация:** LLM преобразует текст в *структурированное действие*.
- **Применение:** внесение изменений в карту пациента посредством **REST API** МИС «СТОММИС».
- ASR → текст → фильтрация/интерпретация:
  - ограничение допустимых команд (whitelist);
  - LLM (например, `qwen3-235b-a22b-fp8`) формирует

Задача 4: устойчивость к ошибкам ASR/LLM

- Ограничение допустимых действий: **белый список интентов** и допустимых параметров.
- Жёсткий формат ответа LLM: **только JSON** по контракту «intent + slots + confidence».
- Валидация перед выполнением: синтаксис JSON $\rightarrow$ схема $\rightarrow$ проверка слотов по справочникам.
- Fail-safe: при низкой уверенности или ошибке валидации возвращается **уточняющий вопрос**, действие не применяется.

Экспериментальное исследование

- Площадка: тестовая среда и СПб ГБУЗ «СП № 8» (предварительная апробация).
- Сравнение двух режимов:
  1. **Baseline:** непрерывная обработка аудиопотока/чанков.
  2. **Предложенный:** VAD в браузере + активация + отправка сегмента команды.
- Метрики:
  - объём отправленного аудио;
  - задержка «конец команды $\rightarrow$ действие в МИС»;
  - качество активации (FP/FN), качество сегментации.

Результаты (оценка на типовом сценарии)

- За 10 минут приёма объём аудио на сервер существенно снижается: вместо всего потока отправляются только команды.
- Задержка выполнения команды остаётся на уровне ≈2–3 с, но возникает **только по событию команды**.
- Снижается риск обработки нерелевантной речи.

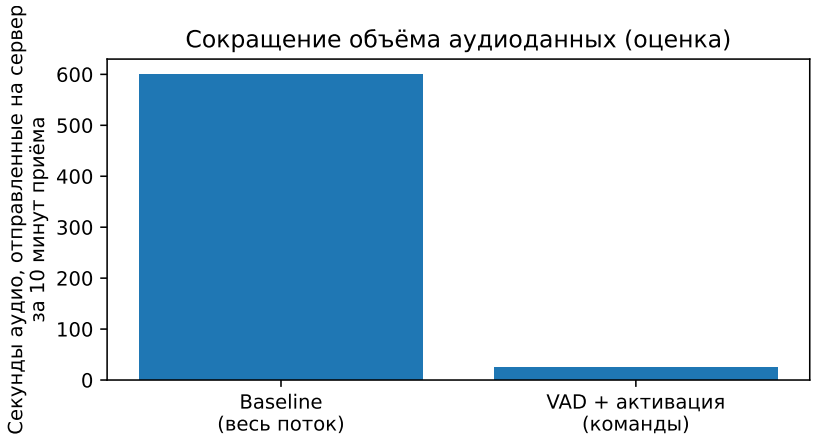

Секунды аудио, отправленные на сервер (оценка).

Результаты работы

- Реализован клиентский модуль VAD в браузере для выделения речевых сегментов и окончания команды по паузе.
- Проработаны два варианта активации голосового режима (клиентский KWS и серверный контроль после ASR); выбран устойчивый режим без обучения на каждом враче.
- Реализован серверный конвейер: приём аудио, транскодирование, ASR (Yandex Speech), интерпретация команд LLM и формирование действий для МИС «СТОММИС».
- Проведено первичное сравнение с baseline и выполнена апробация в реальной поликлинике (результаты требуют дальнейшей стабилизации).

Ограничения и планы

- Чувствительность к шуму и микрофону остаётся важным фактором (особенно для клиентского KWS).
- Зависимость от сети/задержек при обращении к облачному ASR и LLM.
- Следующие шаги:
  - расширение и формализация набора команд;
  - стабилизация в полевых условиях и сбор метрик на большем объёме данных;
  - оптимизация времени ответа (кэширование, локальные модели на сервере).

Дополнительно: таблица сравнения режимов

Показатель	**Baseline**	**VAD + активация**
Длительность аудио за 10 минут	≈600 с	≈18–30 с
Длительность распознаваемого фрагмента	5–15 с	3–5 с
Задержка «конец → действие»	распознавание идёт постоянно	распознавание запускается только после активации
Риск нерелевантной речи	высокий	сниженный
Требования к взаимодействию	нужен ручной контроль	управление голосом без рук

Temporary page!

LaTeX was unable to guess the total number of pages correctly. A
was some unprocessed data that should have been added to the
this extra page has been added to receive it.
If you rerun the document (without altering it) this surplus page
away, because LaTeX now knows how many pages to expect for t
document.